

POLITECHNIKA ŚLĄSKA W GLIWICACH
WYDZIAŁ INŻYNIERII BIOMEDYCZNEJ

Projekt

Biocybernetyka
Uczenie sztucznych sieci neuronowych - przegląd
metod

Daniel Imiołek

Zabrze, 18 grudnia 2017

Spis treści

1. Wprowadzenie	2
1.1 Sztuczna Sieć neuronowa - co to właściwie jest?	2
1.2 Typy Sieci Neuronowych	2
2. Sztuczne Sieci Neuronowe	3
2.1 Metoda reguły delta	3
2.2 Metoda wstecznej propagacji błędów	4
2.3 Sieć Hopfielda	4
2.3.1 Metody uczenia sieci	4
2.4 Sieci Kohonena	5
2.5 Podrozdział 1	5
2.6 Podrozdział 2	5
2.6.1 Znaki Specjalne	5
3. Bibliografia	7

1. Wprowadzenie

1.1 Sztuczna Sieć neuronowa - co to właściwie jest?

Definicją sztucznej sieci neuronowej jest zbiór prostych jednostek obliczeniowych przetwarzających dane, komunikujących się ze sobą i pracujących równolegle.

1.2 Typy Sieci Neuronowych

Wyróżniamy 3 typy sieci neuronowych

- Sieci Jednokierunkowe
- Sieci Rekurencyjne
- Samoorganizujące się mapy

2. Sztuczne Sieci Neuronowe

2.1 Metoda reguły delta

Reguła Delta została opracowana przez Widrowa i Hoffa, znalazła ona zastosowanie do uczenia elementów liniowych i nieliniowych. Reguła delta jest regułą uczenia z nauczycielem. Polega ona na tym, że każdy neuron po otrzymaniu na swoich wejściach określone sygnały (z wejść sieci albo od innych neuronów, stanowiących wcześniejsze piętra przetwarzania informacji) wyznacza swój sygnał wyjściowy wykorzystując posiadaną wiedzę w postaci wcześniej ustalonych wartości współczynników wzmocnienia (wag) wszystkich wejść oraz (ewentualnie) progu. Sposoby wyznaczania przez neurony wartości sygnałów wyjściowych na podstawie sygnałów wejściowych omówione zostały dokładniej w poprzednim rozdziale. Wartość sygnału wyjściowego, wyznaczonego przez neuron na danym kroku procesu uczenia porównywana jest z odpowiedzią wzorcową podaną przez nauczyciela w ciągu uczącym. Jeśli występuje rozbieżność - neuron wyznacza różnicę pomiędzy swoim sygnałem wyjściowym a tą wartością sygnału, która była by - według nauczyciela prawidłowa. Ta różnica oznaczana jest zwykle symbolem greckiej litery delta i stąd nazwa opisywanej metody.

Sygnał błędu wykorzystywany jest przez neuron do korygowania swoich współczynników wagowych:

- wagi zmieniane są tym silniej, im większy jest błąd
- wagi związane z tymi wejściami, na których występowały duże wartości sygnałów wejściowych zmieniane są bardziej niż wagi wejść, na których sygnał wejściowy był niewielki

Znając błąd popełniony przez neuron oraz jego wagi wejściowe możemy łatwo przewidzieć jak beda się zmieniać jego wagi.

$$y = \sum_{i=1}^n w_i x_i = \mathbf{W}^T \mathbf{X},$$

gdzie:

$$\mathbf{X} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{W} = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ \vdots \\ w_n \end{bmatrix}$$

2.2 Metoda wstecznej propagacji błędów


Przez wiele lat nie znaleziono skutecznej metody uczenia sieci wielowarstwowych, dopiero w latach 80-tych zaproponowany został algorytm wstecznej propagacji błędów polegający na tym, że mając wyznaczony błąd $\delta_m^{(j)}$ występujący podczas realizacji j-tego kroku procesu uczenia w neuronie o numerze m można podawać ten błąd wstecz do wszystkich tych neuronów, których sygnały stanowiły wejścia dla m-tego neuronu.

Uczenie odbywa się przez minimalizację odpowiednio zdefiniowanej funkcji celu $Q(W)$, przy czym wektor W reprezentuje wagi sieci poddawane optymalizacji. Najprostszą funkcją celu ma postać błędu średniokwadratowego. Zastosowanie różniczkowalnej funkcji aktywacji umożliwia minimalizację funkcji celu metodami gradientowymi.

2.3 Sieć Hopfielda

<http://th-www.if.uj.edu.pl/~erichter/dydaktyka/Dydaktyka2012/SieciNN-2012/NN-wyklad>

Sieć Hopfielda jest najbardziej znaną siecią, w której kierunek przepływu sygnałów jest odwrócony, posiada sprzężenia zwrotne typu każdy z każdym, jest prostym przykładem sieci rekurencyjnej i często jest nazywana autoasocjatorem, a w ramach tego sprzężenia każdy neuron jest połączony z jednym z wejść oraz z własnym wyjściem.



2.3.1 Metody uczenia sieci

W sieciach Hopfielda wykorzystujemy uczenie oparte na pseudoinwersji macierzy. Tak dobieramy wagi, aby uzyskać na wyjściu takie same wzorce jakie podajemy na wejściu.

$$WX = X \quad (2.1)$$

gdzie W to macierz wag o wymiarze $n \times n$, a X to macierz wzorców o wymiarze $n \times p$ złożoną z p wektorów uczących.

2.4 Sieci Kohonena

Tekst wyrównany do lewej.

Tekst wyśrodkowany.

Tekst wyrównany do prawej.

2.5 Podrozdział 1

2.6 Podrozdział 2

- **Pogrubiony tekst.**

• *Tekst pisany kursywą.*

1. punkt pierwszy

2. punkt drugi

2.6.1 Znaki Specjalne

Hashtag #

Backslash \ Dolar \$

kom 11	kom 12
kom 22 i 23	
kom 31 i kom 32	
kom 41	kom 42

Tab. 2.1: tabela 1

odwołanie do tabeli (tab [2.1](#)):

```
\begin{table} [h]
\begin{tabular}{|l|c|p{7cm}|}
\hline
kom 11 & kom 12 & \\
\hline
\hline
\multicolumn{2}{|c|}{kom 22 i 23} & \\
\hline
\multicolumn{2}{|l|}{kom 31 i kom 32} & \\
\hline
```

Rys. 2.1: dwa rysunki jeden nad drugim

```
kom 41 & kom 42  \\
\hline
\end{tabular}
\centering
\caption{tabela 1}\label{tab_1}
```

$$\left(\prod_{i=\tilde{j}}^{\infty} [\log(i^{\xi})]^M \leq 0 \leftrightarrow \sum_{i=\tilde{j}}^{\infty} \sqrt{\frac{i}{\tilde{j}}} > \sqrt[p]{\tilde{j}} \right) \Rightarrow \text{nic nie wynika} \quad (2.2)$$

Odwołanie do równania (2.2):

```
\begin{equation}\label{moje_równanie}
\left(\prod_{i=\widetilde{j}}^{\infty}[\log(i^{\xi})]^M\leq 0\leftrightarrow\sum_{i=\widetilde{j}}^{\infty}\sqrt{\frac{i}{\widetilde{j}}}>\sqrt[p]{\widetilde{j}}\right)\Rightarrow\text{nic nie wynika}
\end{equation}
```

Odwołanie do rysunku (rys 2.1):

```
\begin{figure}
\raggedright
\includegraphics[scale=0.35]{rysunek1.jpg}
\includegraphics[scale=0.35]{rysunek1.jpg}
\caption{ dwa rysunki jeden nad drugim}\label{rysunek_1}

\end{figure}
```

3. Bibliografia

http://www.dbc.wroc.pl/Content/1908/Rusiecki_Algoritmy_PhD.pdf

https://platforma.polsl.pl/rib/pluginfile.php/2498/mod_resource/content/2/Laboratorium

http://www.neurosoft.edu.pl/media/pdf/tkwater/sztuczna_inteligencja/2_alg_ucz_ssn.pdf